



Université Moulay Smail De Meknès

Faculté des sciences de Meknès

Département d'Informatique

Projet 2

Spécialité : Master Intelligence Artificielle et Analyse des données

Thème

Détection des Visages Humains Générés par IA grâce
au Deep Learning

Encadré par

— Pr. Ali BEKRI

Réalisé par

— Brahim EL HAMDI

2024/2025

SOMMAIRES

Tables des figures.....	3
Introduction générale.....	4
Contexte et Motivation.....	5
I. Contexte du Projet.....	5
II. Motivation.....	5
III. Problématique :	6
l'état de L'ART :	7
IV. Introduction :	7
V. GAN-Generated Faces Detection.....	7
VI. The Analysis of Neural Network Models to Distinguish AI Generated Faces from Real Faces	9
VII. Characteristics and Prevalence of Fake Social Media Profiles with AI-Generated Faces	10
VIII. Global Texture Enhancement for Fake Face Détection In the Wild.....	11
IX. Patch Craft :	13
X. Conclusion	14
Réseaux Génératifs Antagonistes :	15
I. Introduction.....	15
II. Les GANS :	15
2. GANs Conditionals (cGANs : CycleGAN, StarGAN, GauGAN).....	17
III. Conclusion :	19
Méthodologie.....	20
I. Introduction.....	20
II. Jeu de données utilisée :	20
1. Pour visages générés par IA :	20
2. Images de visages réels :	20
III. Concepts du Transfer Learning	22

1. Étapes du Transfer Learning :	22
2. Avantages du Transfer Learning :	23
3. Exemples de modèles pré-entraînés courants :	23
4. Comparaison des approches.....	24
IV. Modèle :	25
1. Modèle ResNet50 :	25
V. Évaluation Expérimentale	29
1. Métriques d'Évaluation	30
VI. Outils et Technologies.....	31
1. Langages de Programmation	31
2. Bibliothèques et Frameworks	31
3. Environnements de Développement :	33
VII. Interface graphique :	33
VIII. Conclusion	34
Conclusion.....	35
BIBLIOGRAPHIE	36

TABLES DES FIGURES

FIGURE 1:PUPILLES D'UN VISAGE HUMAIN REEL ET D'UN VISAGE GENERE PAR UN GAN.	8
FIGURE 2:DEFAUTS DISTINCTIFS COURANTS DES VISAGES GENERES PAR GAN	11
FIGURE 3:CARTES D'ACTIVATION DE CLASSE DU MODELE ENTRAINE	12
FIGURE 4: PROPRIETE DE CONTRASTE DE LA GLCM CALCULEE AVEC TOUS LES MORCEAUX DE PEAU	12
FIGURE 5:L'ANALYSE DES ARTEFACTS	13
FIGURE 6:TYPES DES GANS	16
FIGURE 7:GANS INCONDITIONNELS	17
FIGURE 8:GANS CONDITIONALS	18
FIGURE 9:DISTRIBUTION DES ETIQUETTES	21
FIGURE 10:ECHANTILLON D'IMAGES ETIQUETTES	22
FIGURE 11:TRANSFER LEARNING	22
FIGURE 12:ARCHITECTURE DE RESNET50	26
FIGURE 13:CONNEXIONS RESIDUELLES	27
FIGURE 14:COURBES DE PERTE ET D'EXACTITUDE	29
FIGURE 15:METRIQUES DE PERFORMANCE DU MODELE SUR LE JEU DE DONNEES DE TEST ET TRAIN.	31
FIGURE 16:PYTORCH	32
FIGURE 17:NUMPY	32
FIGURE 18: MATPLOTLIB	32
FIGURE 19 : GRADIO	33
FIGURE 20: INTERFACE GRAPHIQUE (REAL IMAGE)	34
FIGURE 21:INTERFACE GRAPHIQUE (FAKE IMAGE)	34

INTRODUCTION GENERALE

Nous avons assisté à d'immenses progrès dans le domaine de l'intelligence artificielle (IA) au cours des dernières années. L'IA trouve des applications dans des secteurs variés tels que la santé, la mode, l'éducation et l'agriculture, et est considérée comme l'une des prochaines grandes révolutions numériques.

Cependant, l'IA est une arme à double tranchant. Si elle offre un potentiel immense pour des transformations positives, elle peut également être détournée à des fins malveillantes. Entre de mauvaises mains, l'IA devient un outil puissant capable de perturber le quotidien et de propager de la désinformation.

L'une des applications de l'IA qui suscite de vives inquiétudes est la création de deepfakes. Les deepfakes sont des vidéos ou des images truquées, générées par des réseaux de neurones, si convaincantes qu'elles parviennent à tromper même les esprits les plus avertis. Ces dernières années, la technologie des deepfakes a pris d'assaut Internet, avec des visages de célébrités, de politiciens ou même de simples individus étant intégrés de manière réaliste dans des contextes fictifs.

L'année 2020 a marqué un tournant pour les deepfakes, qui sont entrés dans le courant dominant. Ils ont été utilisés dans des publicités, des émissions de télévision et, plus alarmant encore, pour diffuser de fausses informations. Par exemple, en 2018, une vidéo virale montrait Barack Obama insultant Donald Trump. Quelques minutes plus tard, il était révélé qu'Obama n'avait jamais prononcé ces mots : la voix était en réalité celle de Jordan Peele, le réalisateur du film *"Get Out"*, dont la voix avait été numériquement insérée dans la vidéo. Cet exemple illustre à quel point la technologie des deepfakes peut être puissante et trompeuse.

C'est dans ce contexte que notre projet, **"Face to Face"**, vise à relever le défi croissant de distinguer les visages générés par IA des visages réels. Pour cela, nous avons utilisé des techniques de **deep learning**, en nous appuyant sur des modèles de réseaux neuronaux convolutifs (CNN) préentraînés. Ces modèles, connus pour leur efficacité dans le traitement d'images, nous permettent d'analyser les caractéristiques subtiles qui différencient les visages réels des visages synthétiques. En combinant ces approches avancées, nous cherchons à développer un système robuste capable de détecter les deepfakes et de lutter contre la propagation de la désinformation. Ce projet explore non seulement les aspects techniques de la génération d'images par IA, mais souligne également l'importance des considérations éthiques dans le développement et le déploiement de telles technologies. À travers ce travail, nous espérons contribuer à un environnement numérique plus sûr, où l'authenticité des contenus visuels peut être vérifiée et où les risques liés au mauvais usage de l'IA peuvent être atténués.

CONTEXTE ET MOTIVATION

I. Contexte du Projet

Avec les avancées rapides en intelligence artificielle, les modèles génératifs sont devenus capables de produire des images de visages humains d'un réalisme saisissant. Des technologies comme les **réseaux antagonistes génératifs (GANs)** et les **modèles de diffusion** permettent aujourd'hui de créer des visages synthétiques quasi indiscernables de véritables photographies. Ces progrès offrent des applications positives dans divers domaines, notamment l'animation, les jeux vidéo, la création de contenus numériques, et la préservation du patrimoine historique à travers la restauration d'images anciennes.

Toutefois, ces avancées posent également des défis majeurs en matière de **sécurité numérique, de désinformation et d'usurpation d'identité**. Les visages générés par IA sont déjà utilisés à des fins malveillantes, notamment dans la production de faux profils sur les réseaux sociaux, la propagation de fausses informations via des vidéos truquées (deepfakes), et la fraude à l'identité dans les systèmes d'authentification biométrique.

En réponse à ces menaces croissantes, il devient impératif de développer des outils sophistiqués capables de détecter automatiquement les visages synthétiques et de distinguer les images générées artificiellement des véritables photographies. Ces outils doivent être robustes, précis et capables d'évoluer avec les progrès des modèles de génération.

II. Motivation

Face à ces enjeux critiques, plusieurs recherches ont été menées pour proposer des méthodes de détection des visages générés artificiellement. Les approches traditionnelles basées sur la détection d'anomalies visuelles ou de défauts dans les images (tels que des artefacts ou des incohérences dans l'éclairage et les ombres) sont de moins en moins efficaces face aux progrès des modèles récents, qui produisent des images d'une qualité exceptionnelle.

L'une des principales limitations des approches actuelles est leur incapacité à s'adapter rapidement aux nouvelles générations de modèles génératifs. En effet, chaque nouvelle version d'un modèle GAN ou d'un modèle de diffusion améliore la qualité des visages générés, rendant obsolètes les méthodes de détection antérieures.

L'objectif de ce projet est donc de proposer une **approche innovante basée sur le transfert learning avec ResNet50**. Ce modèle pré-entraîné, utilisé initialement pour la classification d'images naturelles, peut être réadapté pour capturer des caractéristiques spécifiques aux visages générés par IA. En exploitant les capacités de **l'apprentissage profond**, notre approche vise à détecter avec précision les subtilités qui distinguent un visage réel d'un visage synthétique, en intégrant des techniques de fine-tuning et d'extraction de caractéristiques pertinentes.

III. Problématique :

La problématique centrale que nous abordons dans ce travail est la suivante :

Comment détecter efficacement les visages générés par intelligence artificielle malgré l'évolution rapide des modèles génératifs ?

Cette question soulève plusieurs défis techniques et méthodologiques :

Adaptabilité aux nouveaux modèles : Les outils de détection doivent être continuellement mis à jour pour reconnaître les visages générés par les modèles les plus récents.

Fiabilité et précision : La réduction des faux positifs (images réelles détectées comme synthétiques) et des faux négatifs (images générées détectées comme réelles) est essentielle pour garantir la pertinence du modèle.

Efficacité computationnelle : L'algorithme doit être optimisé pour fonctionner rapidement et être déployé dans des contextes variés (surveillance en temps réel, intégration dans des plateformes en ligne, etc.).

Explicabilité des résultats : Une meilleure compréhension des critères utilisés par le modèle pour prendre ses décisions permettra d'augmenter la confiance des utilisateurs et des experts en cybersécurité.

En répondant à ces problématiques, ce projet vise à proposer une approche qui pourrait être intégrée dans des solutions pratiques pour renforcer la cybersécurité, la protection des identités et la lutte contre la désinformation.

L'ETAT DE L'ART :

IV. Introduction :

Avec l'essor des modèles d'intelligence artificielle générative, la production d'images synthétiques, notamment de visages humains, est devenue extrêmement réaliste. Les réseaux antagonistes génératifs (GANs) et les modèles de diffusion permettent aujourd'hui de créer des images quasi indiscernables des photographies authentiques, posant ainsi des défis majeurs en matière de cybersécurité, de désinformation et d'usurpation d'identité.

Dans ce contexte, la détection des visages générés par IA est devenue un enjeu fondamental pour préserver l'intégrité des interactions numériques, notamment sur les réseaux sociaux et dans les systèmes d'authentification biométrique. Les travaux de recherche dans ce domaine se sont multipliés, explorant diverses approches basées sur l'apprentissage profond, l'analyse de caractéristiques physiologiques et les heuristiques visuelles.

Cette section présente un état de l'art des techniques existantes pour la détection des visages générés artificiellement. Nous y analyserons les stratégies développées, les défis rencontrés et les tendances émergentes dans ce domaine, en nous appuyant sur les contributions scientifiques majeures.

V. GAN-Generated Faces Detection

Dans le document de recherche intitulé "GAN-Generated Faces Detection: A Survey and New Perspectives", les auteurs dressent un panorama complet des avancées scientifiques dans le domaine de la détection des visages générés par les réseaux antagonistes génératifs (Generative Adversarial Networks - GANs). Avec l'amélioration continue de ces modèles, les images synthétiques sont devenues pratiquement indiscernables des images réelles, posant ainsi de sérieux défis en matière de sécurité, de lutte contre la désinformation et d'authentification des identités numériques.

Les travaux recensés dans cette étude se structurent autour de quatre grandes approches méthodologiques :

1. **Les méthodes basées sur l'apprentissage profond**, qui exploitent des réseaux neuronaux convolutifs (CNN) pour distinguer les images réelles des images synthétiques en extrayant des caractéristiques subtiles. Bien qu'efficaces en termes de précision, ces modèles souffrent d'un manque

d'interprétabilité, ce qui complique leur adoption dans des contextes nécessitant une justification des décisions.

2. **Les méthodes basées sur des indices physiques**, qui se focalisent sur les incohérences de rendu inhérentes aux GANs, comme les reflets lumineux dans les yeux ou les variations non naturelles d'ombres et d'illuminations. Ces techniques offrent une meilleure explicabilité que les modèles purement neuronaux, mais elles peuvent être sensibles aux modifications des architectures de génération d'images.



Figure 1: Pupilles d'un visage humain réel et d'un visage généré par un GAN.

3. **Les méthodes physiologiques**, qui analysent des artefacts biologiques présents dans les visages synthétiques, tels que des asymétries faciales, des formes de pupilles irrégulières ou des variations de teintes incohérentes entre différentes parties du visage. Ces approches sont particulièrement intéressantes pour identifier des indices universels permettant de discriminer les visages réels des visages générés.
4. **L'évaluation des performances humaines**, qui révèle que les observateurs humains ont une capacité limitée à discerner les visages réels des visages synthétiques, avec des taux de succès oscillant entre 50 et 60 %. Ces résultats démontrent l'importance de développer des solutions automatisées pour renforcer la détection des visages générés par IA.

L'étude souligne également l'impact des jeux de données utilisés pour l'apprentissage et l'évaluation des modèles de détection, parmi lesquels FFHQ, CelebA, RAISE pour les images réelles, et StyleGAN, StyleGAN2, StyleGAN3 pour les images synthétiques. Bien que les progrès récents aient permis d'améliorer la robustesse des modèles de détection, plusieurs défis persistent, notamment l'adaptation aux nouvelles générations de GANs, la nécessité d'améliorer

l'explicabilité des décisions, la résistance aux attaques adversariales et la gestion du déséquilibre des bases de données où les images réelles sont largement majoritaires.

Ainsi, cette revue met en évidence le caractère évolutif et complexe de la détection des visages générés par IA. Face à la sophistication croissante des modèles génératifs, les chercheurs doivent développer des approches hybrides combinant apprentissage profond, analyse physique et biométrie pour proposer des solutions fiables, explicables et adaptées aux enjeux de cybersécurité et de protection de l'identité numérique.

VI. The Analysis of Neural Network Models to Distinguish AI Generated Faces from Real Faces

Dans le document de recherche intitulé "The Analysis of Neural Network Models to Distinguish AI Generated Faces from Real Faces", les auteurs explorent les approches basées sur l'intelligence artificielle pour différencier les visages générés artificiellement des visages réels. La montée en puissance des technologies de génération d'images via des modèles de type Generative Adversarial Networks (GANs) soulève des enjeux cruciaux en matière de sécurité et de protection des données personnelles, notamment dans des domaines sensibles comme la reconnaissance faciale aux points de contrôle aéroportuaires ou l'authentification numérique.

L'étude se focalise sur l'analyse et l'évaluation de plusieurs modèles de réseaux neuronaux profonds afin de proposer une méthode robuste et efficace de détection des visages synthétiques. Les chercheurs ont testé trois architectures de deep learning : **VGG16, EfficientNetB3 et ConvNeXt-T**, en exploitant un jeu de données de 140 000 images comprenant à parts égales des visages réels et générés artificiellement. Leurs résultats indiquent des taux de précision extrêmement élevés, atteignant 100 % en phase d'entraînement et 99,9 % en validation, démontrant ainsi l'efficacité des modèles étudiés. Parmi eux, **VGG16 s'est révélé être le plus performant.**

Les contributions principales de cette étude résident dans l'optimisation des architectures de détection, l'adaptation des modèles aux variations des images (éclairage, arrière-plans, expressions faciales) et l'amélioration de la robustesse aux attaques adversariales. En outre, l'approche adoptée intègre des techniques avancées comme l'apprentissage fédéré et des stratégies de régularisation visant à rendre les décisions des modèles plus interprétables et transparentes.

Toutefois, plusieurs défis subsistent. Les auteurs soulignent l'importance de poursuivre les recherches pour améliorer la généralisation des modèles face aux évolutions des GANs, d'explorer des méthodes hybrides combinant différentes approches et de tester ces algorithmes sur des bases de données plus diversifiées. Cette étude constitue donc une avancée significative dans le domaine de la détection des visages générés par IA et ouvre des perspectives prometteuses pour le développement d'outils plus fiables et explicables dans le domaine de la cybersécurité et de la reconnaissance faciale.

VII. Characteristics and Prevalence of Fake Social Media Profiles with AI-Generated Faces

Dans le document de recherche intitulé *"Characteristics and Prevalence of Fake Social Media Profiles with AI-Generated Faces"*, les auteurs analysent l'utilisation des visages générés par l'IA, notamment par les réseaux antagonistes génératifs (*Generative Adversarial Networks* - GANs), dans les profils de réseaux sociaux. L'étude met en évidence l'essor des faux comptes exploitant ces images synthétiques pour des activités malveillantes telles que la propagation de désinformation, les escroqueries en ligne et l'amplification de contenus dans le cadre de campagnes coordonnées.

Les chercheurs ont constitué un ensemble de données de **1 420 comptes Twitter** utilisant des photos de profil générées par GANs. Ces comptes présentent des noms réalistes et des descriptions plausibles afin d'imiter de véritables utilisateurs humains. Leur activité est souvent automatisée et orientée vers des pratiques frauduleuses telles que :

- **L'usurpation d'identité** via des profils entièrement fictifs.
- **L'escroquerie et le spam**, notamment par la diffusion de faux messages et de liens malveillants.
- **L'amplification coordonnée**, où plusieurs comptes interagissent de manière artificielle pour promouvoir certains contenus.

Afin de détecter ces comptes, les auteurs ont exploité une caractéristique commune aux visages générés par GANs : la **position cohérente des yeux** sur les images produites. Cette propriété a permis de développer un indicateur nommé **GANEyeDistance**, qui évalue la proximité des coordonnées des yeux avec celles typiques des images GAN. Grâce à cette approche, ils ont analysé un échantillon aléatoire de **254 275 utilisateurs Twitter** et ont estimé que **0,021 % à 0,044 % des comptes actifs utilisent des images générées par IA**, ce qui représente environ **10 000 comptes par jour**.




Figure 2: Défauts distinctifs courants des visages générés par GAN

L'étude souligne les **défis croissants liés aux faux profils IA**, notamment leur impact sur la confiance et la sécurité en ligne. Elle propose plusieurs pistes pour améliorer la détection, notamment en développant de nouveaux algorithmes robustes capables d'identifier les modèles de génération d'images plus avancés, tels que les modèles de diffusion (*Diffusion Models*). Enfin, elle insiste sur la nécessité d'une **réglementation stricte et d'une sensibilisation des utilisateurs** pour limiter l'impact des comptes frauduleux exploitant l'IA.

VIII. Global Texture Enhancement for Fake Face Detection In the Wild

Dans le document de recherche intitulé "Global Texture Enhancement for Fake Face Detection In the Wild", les auteurs Zhengzhe Liu, Xiaojuan Qi et Philip H. S. Torr proposent une nouvelle approche pour détecter les visages générés par des réseaux antagonistes génératifs (GANs). Leur travail se concentre sur l'analyse des différences texturales entre les visages réels et ceux générés par des GANs, en mettant en évidence que les textures des visages faux sont significativement différentes de celles des visages réels. Ils introduisent une architecture innovante, appelée Gram-Net, qui exploite les représentations globales des textures d'image pour améliorer la robustesse et la généralisation de la détection des visages faux. Les expériences menées sur plusieurs jeux de données montrent que Gram-Net surpasse les méthodes existantes, en particulier dans des scénarios où les images ont subi des modifications telles que la réduction de résolution, la compression JPEG, le flou ou l'ajout de bruit. De plus, Gram-Net démontre une capacité de généralisation supérieure pour détecter des visages générés par des GANs non vus pendant l'entraînement, ainsi que des images naturelles fausses. Ce travail ouvre

une nouvelle voie prometteuse pour la détection des images générées par des GANs dans des conditions réalistes, en mettant l'accent sur l'importance des informations texturales globales.



Figure 3: Cartes d'activation de classe du modèle entraîné

Pour illustrer leurs découvertes, les auteurs présentent une analyse détaillée des cartes d'activation de classe (Class Activation Maps - CAM) issues d'un modèle ResNet entraîné, comme le montre la Figure . Cette figure met en évidence les régions discriminantes (en couleur chaude) que le modèle CNN utilise pour détecter les visages faux, principalement concentrées sur les zones texturées comme la peau et les cheveux. En revanche, les artefacts visibles (indiqués par des boîtes rouges) tels que des boucles d'oreilles asymétriques, des lettres irrégulières ou des dents mal alignées, sont faiblement activés par le CNN, ce qui suggère que les humains et les modèles CNN utilisent des indices différents pour identifier les visages faux.

distance (d)	1	2	5	10	15	20
Dataset						
CelebA-HQ	8.68	12.37	61.52	117.94	181.30	237.30
StyleGAN(on CelebA-HQ)	4.92	8.84	47.40	93.79	146.33	193.49
PGGAN(on CelebA-HQ)	6.45	11.43	58.20	112.28	172.72	226.40

Figure 4: Propriété de contraste de la GLCM calculée avec tous les morceaux de peau

De plus, les auteurs analysent les propriétés de contraste des textures à l'aide de la matrice de co-occurrence de niveaux de gris (Gray-Level Co-occurrence Matrix - GLCM), comme le montre le Tableau . Ce tableau compare les contrastes texturaux entre les visages réels (CelebA-HQ) et les visages générés par StyleGAN et PGGAN. Les résultats montrent que les visages réels présentent un contraste textural plus fort à toutes les distances mesurées, ce qui confirme que les GANs ont du mal à reproduire fidèlement les textures complexes des images réelles.

En résumé, ce travail démontre que les textures globales sont un indicateur robuste pour la détection des visages faux, et que Gram-Net, en exploitant ces informations, offre une solution efficace et généralisable pour relever les défis posés par les images générées par des GANs dans des conditions réalistes.

IX. Patch Craft :

Dans le document de recherche intitulé "PatchCraft: Exploring Texture Patch for Efficient AI-generated Image Detection", les auteurs Nan Zhong, Yiran Xu, Sheng Li, Zhenxing Qian et Xinpeng Zhang proposent une nouvelle méthode pour détecter les images générées par des modèles d'intelligence artificielle (IA). Leur approche se concentre sur l'analyse des patches de texture dans les images, qui révèlent des traces laissées par les modèles génératifs, contrairement aux informations sémantiques globales qui peuvent être trompeuses. Les auteurs introduisent une technique de prétraitement appelée Smash&Reconstruction, qui efface les informations sémantiques globales et met en avant les patches de texture. Cette méthode permet de mieux capturer les artefacts laissés par les modèles génératifs, en particulier dans les régions riches en texture, où les fluctuations de pixels sont plus significatives.

Leur approche repose sur l'exploitation du contraste de corrélation inter-pixels entre les régions riches et pauvres en texture, ce qui permet de détecter les images générées par une large gamme de modèles génératifs, y compris les GANs et les modèles basés sur la diffusion. Les résultats expérimentaux montrent que leur méthode surpasse les approches existantes, en particulier dans des scénarios où les images ont subi des modifications telles que la compression JPEG, le flou ou la réduction de résolution. De plus, leur modèle démontre une excellente généralisation, capable de détecter des images générées par des modèles non vus pendant l'entraînement.




Figure 5:l'analyse des artefacts

Pour illustrer leur méthode, les auteurs présentent une analyse visuelle des patches de texture avant et après le prétraitement Smash&Reconstruction, comme le montre la Figure 4. Cette figure montre comment les informations sémantiques globales sont supprimées, laissant place à des patches de texture qui révèlent les artefacts des modèles génératifs. Cette visualisation met en évidence l'efficacité

de leur approche pour se concentrer sur les détails texturaux plutôt que sur le contenu sémantique global.

En résumé, ce travail propose une nouvelle direction prometteuse pour la détection des images générées par l'IA, en exploitant les caractéristiques texturales locales et en améliorant la robustesse et la généralisation des détecteurs. Les résultats expérimentaux démontrent que leur méthode est particulièrement efficace pour identifier des images générées par des modèles modernes, y compris ceux basés sur la diffusion, ce qui en fait une solution adaptée aux défis posés par les images synthétiques réalistes dans des conditions réelles.

X. Conclusion

Les méthodes actuelles de détection des visages générés par IA, bien qu'efficaces, rencontrent encore des défis face à la sophistication des modèles récents. Les approches basées sur l'apprentissage profond et l'analyse de caractéristiques visuelles montrent des résultats intéressants, mais restent limitées par la rapidité de l'évolution des générateurs d'images.

Dans ce contexte, cette étude propose une approche différente en utilisant le **transfert learning** avec **ResNet50**, une méthode plus robuste qui pourrait surpasser les solutions existantes et améliorer la détection des visages générés par IA dans des applications pratiques, notamment pour la cybersécurité et la prévention de la désinformation.

RESEAUX GENERATIFS ANTAGONISTES :

I. Introduction

Les réseaux génératifs antagonistes (GANs) ont révolutionné la génération d'images synthétiques en permettant de créer des visuels d'un réalisme saisissant. Depuis leur introduction par Ian Goodfellow en 2014, ces modèles ont connu de nombreuses améliorations et applications, notamment dans la création de visages humains artificiels. Grâce à leur architecture opposant un générateur et un discriminateur, les GANs ont permis des avancées significatives dans le domaine de la synthèse d'images, avec des modèles de plus en plus performants et adaptatifs. Cette section explore les principaux types de GANs utilisés pour la génération de visages, leurs caractéristiques et leurs applications.

II. Les GANS :

Les GANs (Generative Adversarial Networks) sont devenus une pierre angulaire de l'IA, en particulier pour la génération d'images synthétiques. Introduits par Ian Goodfellow en 2014, ils reposent sur deux réseaux neuronaux :

Générateur : Crée des images à partir d'un vecteur aléatoire (bruit), en apprenant progressivement à produire des images ressemblant aux données réelles.

Discriminateur : Évalue si l'image est réelle ou générée. Il fournit un retour au générateur pour qu'il améliore sa production.

Ce processus adversarial fonctionne par itérations : le générateur améliore ses sorties pour tromper le discriminateur, et ce dernier affine sa capacité à détecter les fausses images.




Figure 6:types des GANS

1. GANs Inconditionnels (ProGAN, StyleGAN, BigGAN) :

Les GANs inconditionnels (Generative Adversarial Networks) sont des réseaux de génération qui produisent des images sans condition préalable, c'est-à-dire qu'ils ne reposent pas sur des informations spécifiques comme des labels ou des caractéristiques d'entrée particulières. Ces modèles apprennent à générer des images réalistes à partir de données brutes, en capturant la distribution de l'ensemble de données d'origine.

ProGAN : Utilise un entraînement progressif, où la génération commence par de petites résolutions et augmente graduellement, facilitant l'apprentissage des détails fins.

StyleGAN : Introduit un espace latent modulaire, permettant de contrôler divers aspects de l'image (forme du visage, texture de la peau) par des vecteurs de style appliqués à différents niveaux.

BigGAN : Augmente la capacité du modèle et utilise des techniques de régularisation avancées pour produire des images de haute qualité sur de grands ensembles de données.

Points forts : Capacité à générer des images très réalistes et détaillées, bien adaptées aux tâches où la diversité des échantillons est essentielle.




Figure 7:GANs Inconditionnels

2. GANs Conditionals (cGANs : CycleGAN, StarGAN, GauGAN)

Les GANs conditionnels sont des variantes des GANs où la génération d'images dépend d'une condition donnée, telle que des labels, des croquis ou des attributs spécifiques. Ces modèles permettent un contrôle plus précis sur le processus de génération, ce qui les rend utiles pour des applications nécessitant un contrôle explicite sur les images produites.

- **CycleGAN** : Apprend à convertir des images d'un domaine à un autre (ex : chevaux zèbres) sans avoir besoin d'images appariées, via une perte de cycle consistant à revenir à l'image initiale après une double conversion.
- **StarGAN** : Permet la manipulation simultanée de plusieurs attributs (comme la couleur de cheveux, l'âge, l'expression) en utilisant un vecteur de condition multi-attribut.
- **GauGAN** : Génère des images réalistes à partir de simples croquis, grâce à un réseau qui interprète des segments dessinés comme des objets distincts et les rend visuellement crédibles.

Points forts : Une génération précise et adaptable, essentielle dans des contextes où des contrôles spécifiques sont requis.




Figure 8:GANs Conditionals

Aspect	GANs inconditionnels	GANs conditionnels
Entrée du générateur	Bruit aléatoire uniquement.	Bruit aléatoire + étiquettes/attributs.
Contrôle des sorties	Aucun contrôle sur les images générées.	Contrôle total via les attributs spécifiés.
Utilisation	Génération libre d'images réalistes.	Génération d'images selon des critères précis.

3. Défis :

- Évolution rapide des architectures rendant la détection difficile, car les modèles s'améliorent constamment.
- Nécessité d'une adaptation continue des détecteurs face à la diversité croissante des techniques de génération.
- Exemples : Les deepfakes utilisés dans des cyberattaques ont montré la difficulté d'identifier des images truquées dans des vidéos haute résolution.
- Les réseaux comme StyleGAN3 créent des visages pratiquement parfaits, compliquant leur détection, même par des systèmes avancés.
- Les défis incluent la gestion des variations de luminosité, angles et expressions, souvent maîtrisées par les générateurs modernes.

L'étude de ces techniques justifie l'utilisation du Transfer Learning avec ResNet50, un modèle pré-entraîné qui sera affiné pour détecter les visages générés par IA grâce à sa capacité à extraire efficacement des caractéristiques complexes à partir d'images.

III. Conclusion :

Les GANs ont démontré un potentiel remarquable dans la génération d'images synthétiques, notamment pour la création de visages humains ultra-réalistes. L'évolution de ces modèles, des GANs inconditionnels comme StyleGAN aux GANs conditionnels comme CycleGAN et StarGAN, a permis d'accroître le contrôle et la diversité des images produites. Cependant, ces avancées posent également des défis en matière d'authenticité et de détection des images générées artificiellement. Comprendre ces architectures est essentiel pour développer des

METHODOLOGIE

I. Introduction

Dans ce projet, l'objectif principal est de développer un modèle capable de détecter les visages générés par intelligence artificielle (IA) à partir d'un ensemble de données combinant des images réelles et générées. Le jeu de données utilisé comprend deux ensembles distincts : d'une part, des images de visages générés par IA obtenues à partir du site **ThisPersonDoesNotExist.com**, utilisant le modèle StyleGAN pour créer des visages synthétiques ; d'autre part, des images de visages réels issues du jeu de données **Flickr-Faces-HQ (FFHQ)**, connu pour sa diversité démographique et la qualité de ses images. Ce travail repose également sur l'utilisation de la méthode du **Transfer Learning** pour adapter un modèle pré-entraîné à cette tâche de détection spécifique. Cette méthodologie a pour but de réduire les besoins en données et en temps d'entraînement, tout en améliorant la performance du modèle.

II. Jeu de données utilisée :

Le jeu de données utilisé dans ce projet comprend deux ensembles distincts :

1. Pour visages générés par IA :

Ces images ont été collectées à l'aide du site ThisPersonDoesNotExist.com, qui génère des visages synthétiques à l'aide de StyleGAN. Un script Python a été développé pour télécharger automatiquement ces images, avec un mécanisme de détection des doublons basé sur le hachage MD5. Initialement, 1 million d'images ont été générées, puis un échantillon de 70 000 images uniques a été sélectionné.

2. Images de visages réels :

Cet ensemble provient du dataset Flickr-Faces-HQ (FFHQ) collecté par Nvidia, connu pour sa diversité démographique et sa haute qualité. Chaque image est de résolution 1024x1024 pixels, assurant une représentation claire et détaillée. La taille finale des images utilisée dans ce projet après prétraitement est de (64, 256, 256, 3), correspondant à 64 images par batch, chacune de 256x256 pixels avec 3 canaux de couleur (RVB)

Distribution des étiquettes :

Le graphique intitulé "Distribution des étiquettes (labels) dans les dossiers" montre la répartition des images entre les étiquettes "faux" et "réel" dans les dossiers "train",

"valid", et "test". L'axe des x représente les étiquettes, tandis que l'axe des y indique le nombre d'images, avec des barres colorées pour distinguer les dossiers. On observe que le dossier "train" contient le plus d'images, suivi de "valid" et "test", et que les images "réelles" sont plus nombreuses que les "fausses" dans tous les dossiers. Ce déséquilibre entre les classes pourrait nécessiter des techniques comme l'augmentation des données ou le suréchantillonnage pour éviter un biais du modèle. Le graphique met en évidence la structure du jeu de données et les aspects à considérer pour un prétraitement efficace avant l'entraînement.




Figure 9: Distribution des étiquettes

Cette image montre un échantillon d'images étiquetées "faux" et "réel", provenant des dossiers "train" et "test". Chaque image est accompagnée de son étiquette et de son dossier d'origine. La visualisation confirme la distinction entre les deux classes et la répartition des données, principalement issues du dossier "train". Elle permet de vérifier la qualité des images et la précision des étiquettes, assurant ainsi que le jeu de données est bien structuré pour l'entraînement et les tests.




Figure 10: échantillon d'images étiquetées

III. Concepts du Transfer Learning

Le Transfer Learning repose sur l'idée de transférer les connaissances acquises par un modèle sur une tâche source (généralement une tâche générique avec une grande quantité de données) à une tâche cible (une tâche spécifique avec peu de données). En vision par ordinateur, cela implique de réutiliser les couches d'un modèle pré-entraîné (par exemple, sur ImageNet) et de les adapter à un nouveau problème.




Figure 11: Transfer Learning

1. Étapes du Transfer Learning :

a. Sélection du modèle pré-entraîné :

- Choisir un modèle qui a été entraîné sur une grande base de données (comme ImageNet) et qui a appris des caractéristiques génériques (edges, textures, motifs, etc.).

b. Adaptation du modèle :

- Gel des couches : Les premières couches du modèle (qui détectent des caractéristiques de bas niveau comme les bords et les textures) sont gelées pour éviter de les ré-entraîner.
- Remplacement des couches finales : Les couches fully connected (denses) en fin de modèle sont remplacées pour s'adapter au nombre de classes de la nouvelle tâche.
- c. Entraînement :
 - Le modèle est ré-entraîné sur le nouveau jeu de données, en ajustant uniquement les couches non gelées.

2. Avantages du Transfer Learning :

- Réduction du temps d'entraînement : Les modèles pré-entraînés ont déjà appris des caractéristiques génériques, ce qui réduit le temps nécessaire pour entraîner un modèle à partir de zéro.
- Moins de données nécessaires : Le Transfer Learning est particulièrement utile lorsque l'on dispose de peu de données annotées, car il permet de tirer parti des connaissances acquises sur des bases de données plus grandes.
- Meilleures performances : Les modèles pré-entraînés ont souvent des performances supérieures sur des tâches spécifiques, car ils ont été entraînés sur des millions d'images.
- Facilité d'utilisation : Des frameworks comme TensorFlow, PyTorch et Keras fournissent des modèles pré-entraînés prêts à l'emploi, ce qui simplifie leur utilisation.

3. Exemples de modèles pré-entraînés courants :

Plusieurs architectures de réseaux de neurones convolutifs (CNNs) ont été pré-entraînées sur des bases de données comme ImageNet et sont largement utilisées en Transfer Learning. Voici quelques-uns des modèles les plus populaires :

- VGG (Visual Geometry Group)** : est une architecture simple mais efficace, caractérisée par des couches convolutives empilées avec de petits filtres (3x3) et des couches de pooling. Les versions les plus couramment utilisées sont VGG16 (16 couches) et VGG19 (19 couches). Ses avantages incluent la

simplicité et la performance élevée sur des tâches de classification d'images. Il est souvent utilisé pour la classification d'images, la détection d'objets et la segmentation sémantique.

- b. **ResNet (Residual Network)**: introduit le concept de "résidus" (skip connections) pour permettre l'entraînement de réseaux très profonds (jusqu'à 152 couches ou plus) sans rencontrer de problèmes de vanishing gradients. Les versions les plus populaires sont ResNet50, ResNet101 et ResNet152. Ses avantages incluent la capacité à entraîner des réseaux très profonds avec une performance élevée. Il est couramment utilisé pour la classification d'images, la détection d'objets et la segmentation.
- c. **Inception (GoogLeNet)**: utilise des modules appelés "Inception modules" qui appliquent des convolutions de différentes tailles en parallèle pour capturer des caractéristiques à plusieurs échelles. Les versions les plus utilisées sont InceptionV1 (GoogLeNet), InceptionV3 et InceptionV4. Ses avantages incluent l'efficacité en termes de calcul et la performance élevée. Il est souvent utilisé pour la classification d'images, la détection d'objets et la reconnaissance de scènes.
- d. **EfficientNet**: est une famille de modèles optimisés pour offrir un équilibre entre performance et efficacité computationnelle. Il utilise un scaling compound pour ajuster la profondeur, la largeur et la résolution du réseau. Les versions vont de EfficientNet-B0 à EfficientNet-B7, où B0 est le plus petit et B7 le plus grand. Ses avantages incluent une haute performance avec une faible consommation de ressources. Il est couramment utilisé pour la classification d'images, la détection d'objets et la segmentation.
- e. **MobileNet**: est conçu pour être léger et efficace, ce qui le rend idéal pour les applications mobiles et embarquées. Il utilise des convolutions séparables en profondeur pour réduire le nombre de paramètres. Les versions les plus récentes sont MobileNetV1, MobileNetV2 et MobileNetV3. Ses avantages incluent sa légèreté et sa rapidité, tout en maintenant une bonne performance. Il est souvent utilisé pour les applications mobiles, la reconnaissance en temps réel et l'IoT.
- f. **DenseNet**: connecte chaque couche à toutes les autres couches précédentes, ce qui permet une meilleure propagation du gradient et une réutilisation des caractéristiques. Les versions les plus utilisées sont DenseNet121, DenseNet169 et DenseNet201. Ses avantages incluent la réduction du nombre de paramètres et l'amélioration de la performance. Il est couramment utilisé pour la classification d'images et la segmentation.

4. Comparaison des approches

Les méthodes traditionnelles de détection de visages artificiels, telles que les techniques basées sur des caractéristiques spécifiques (comme l'analyse des textures, des bords ou des couleurs), présentent plusieurs limites :

- Sensibilité aux variations : Elles sont souvent sensibles aux changements d'éclairage, de pose ou de qualité d'image.
- **Complexité limitée** : Elles peinent à capturer des motifs complexes et subtils présents dans les images générées par des modèles avancés comme StyleGAN.
- **Besoin de nombreuses règles manuelles** : La création de filtres spécifiques pour chaque anomalie potentielle est chronophage et peu évolutive.

Avantages du Transfer Learning :

- **Apprentissage de caractéristiques complexes** : Les modèles pré-entraînés comme ResNet50 capturent des motifs subtils difficiles à détecter manuellement.
- **Réduction du besoin de données** : En transférant les connaissances acquises sur de vastes bases de données, il est possible de travailler avec des ensembles de données plus petits.
- **Adaptabilité** : Les couches finales peuvent être ajustées spécifiquement pour détecter les visages artificiels, offrant une grande flexibilité.
- **Gain de temps et de ressources** : Moins d'itérations d'entraînement sont nécessaires, permettant de se concentrer sur l'optimisation des résultats.
- **Robustesse face aux variations** : Les modèles transférés gèrent mieux les changements d'éclairage, de pose ou de qualité, garantissant des performances plus stables.

L'approche par Transfer Learning, en particulier avec ResNet50, permet de surmonter les limites des méthodes traditionnelles et d'assurer une détection précise et efficace des visages générés par IA.

IV. Modèle :

1. Modèle ResNet50 :

Pour ce projet, j'ai choisi d'utiliser le modèle pré-entraîné ResNet50, une architecture de réseau de neurones convolutifs (CNN) profonde développée par Microsoft Research en 2015. ResNet50 est une variante de l'architecture ResNet (Réseau Résiduel), où le "50" fait référence aux 50 couches profondes du réseau.

ResNet50 est un modèle puissant pour la classification d'images, capable d'être entraîné sur de grands ensembles de données et d'atteindre des performances de pointe. L'une de ses innovations clés est l'utilisation de connexions résiduelles, qui permettent au réseau d'apprendre des fonctions résiduelles mappant l'entrée à la sortie désirée. Ces connexions résiduelles permettent au réseau d'apprendre des architectures beaucoup plus profondes que ce qui était possible auparavant, sans souffrir du problème des gradients disparaissants.

a. Architecture de ResNet50 :

L'architecture de ResNet50 est divisée en quatre parties principales :

- **Couches Convolutives** : Ces couches sont responsables de l'extraction des caractéristiques de l'image d'entrée, telles que les bords, les textures et les formes. Elles sont suivies de couches de max pooling, qui réduisent les dimensions spatiales des cartes de caractéristiques tout en préservant les caractéristiques les plus importantes.
- **Bloc d'Identité** : Ce bloc passe l'entrée à travers une série de couches convolutives et ajoute l'entrée à la sortie. Cela permet au réseau d'apprendre des fonctions résiduelles.
- **Bloc Convolutif** : Similaire au bloc d'identité, mais avec l'ajout d'une couche convolutive 1x1 pour réduire le nombre de filtres avant la couche convolutive 3x3.
- **Couches Complètement Connectées** : Ces couches sont responsables de la classification finale. La sortie de la dernière couche complètement connectée est passée à travers une fonction d'activation softmax pour produire les probabilités finales de classe.




Figure 12: Architecture de ResNet50

b. Pourquoi ResNet50 ? :

Plusieurs raisons justifient mon choix de ResNet50 pour ce projet :

- **Performance** : ResNet50 a été entraîné sur le large ensemble de données ImageNet, contenant plus de 14 millions d'images et 1000 classes. Sur ce dataset, ResNet50 a atteint un taux d'erreur de 22.85%, ce qui est comparable à la performance humaine (taux d'erreur de 5.1%).
- **Connexions Résiduelles** : Les connexions résiduelles (ou "skip connections") sont une caractéristique clé de ResNet50. Elles permettent au réseau

d'apprendre des architectures plus profondes sans souffrir du problème des gradients disparaissants. Ce problème survient lorsque les gradients des paramètres dans les couches plus profondes deviennent très petits, rendant difficile l'apprentissage et l'amélioration de ces couches. Les connexions résiduelles permettent à l'information de circuler directement de l'entrée à la sortie du réseau, contournant une ou plusieurs couches.




Figure 13: Connexions Résiduelles

- **Polyvalence** : ResNet50 a été utilisé avec succès dans diverses tâches de classification d'images, telles que la détection d'objets, la reconnaissance faciale et l'analyse d'images médicales. Il peut également être utilisé comme extracteur de caractéristiques pour d'autres tâches, comme la détection d'objets et la segmentation sémantique.

c. Comparaison avec d'Autres Modèles Pré-entraînés :

Plusieurs autres modèles préentraînés sont disponibles, tels que VGG16, InceptionV3, et EfficientNet. Cependant, ResNet50 offre un bon équilibre entre complexité et performance. Par exemple :

- **VGG16** : Bien que VGG16 soit simple et efficace, il a un nombre de paramètres beaucoup plus élevé que ResNet50, ce qui le rend plus coûteux en termes de calcul.
- **InceptionV3** : InceptionV3 est également performant, mais son architecture est plus complexe et moins intuitive que ResNet50.
- **EfficientNet** : EfficientNet est conçu pour être plus efficace en termes de calcul, mais il peut ne pas offrir la même flexibilité et performance que ResNet50 pour certaines tâches spécifiques.

V. Processus d'Entraînement :

1. Fonction de Perte et Optimiseur :

Pour entraîner notre modèle **ResNet50** sur la tâche de détection de visages générés par l'IA, nous avons utilisé :

- **Fonction de perte : Cross-Entropy Loss**, adaptée aux tâches de classification binaire. Cette fonction mesure l'écart entre les prédictions du modèle et les étiquettes réelles :

$$\mathcal{L} = - \sum_{i=1}^N y_i \log(\hat{y}_i)$$

Où :

- y_i est la véritable étiquette (0 pour un visage réel, 1 pour un visage généré).
- $\hat{y}_i$ est la probabilité prédite par le modèle après l'application de **softmax**.
- N est le nombre total d'exemples.

- **Optimiseur** : Nous avons utilisé **Adam (Adaptive Moment Estimation)**, un algorithme d'optimisation efficace qui combine les avantages d'Adagrad et RMSprop. Il met à jour les poids selon la règle suivante :

$$\theta_{t+1} = \theta_t - \frac{\alpha \cdot m_t}{\sqrt{v_t} + \epsilon}$$

Où :

- $\alpha = 0.001$ est le taux d'apprentissage.
- m_t et v_t sont les estimations des moyennes et variances des gradients.
- Un **facteur de régularisation (weight decay)** de $1e - 4$ a été ajouté pour améliorer la généralisation du modèle.

L'entraînement a été réalisé sur **10 époques**, avec mise à jour des poids après chaque batch.

2. Courbes de Perte et d'Exactitude :

L'évolution de la performance du modèle au cours des époques est illustrée par les courbes suivantes :




Figure 14: Courbes de Perte et d'Exactitude

- **À gauche (Loss Curve) :**

- La **perte d'entraînement** diminue progressivement, indiquant que le modèle apprend efficacement.
- La **perte de validation** reste relativement stable après quelques époques, montrant une bonne convergence du modèle.

- **À droite (Accuracy Curve) :**

- L'**exactitude d'entraînement** augmente continuellement et atteint un niveau proche de **96%**.
- L'**exactitude de validation** suit une tendance similaire, atteignant environ **94%**

VI. Évaluation Expérimentale

L'évaluation expérimentale de notre modèle de détection de visages générés par IA a été réalisée en utilisant des données réelles et générées par l'IA. Cette approche a permis d'améliorer significativement la performance du modèle, en particulier en ce qui concerne la précision et la capacité à discriminer les visages réels des visages générés.

1. Métriques d'Évaluation

- Précision (Accuracy) : La précision est une métrique fondamentale qui représente la proportion d'exemples correctement classés (réels ou générés) parmi l'ensemble des exemples. Elle est calculée comme suit :

$$\text{Précision} = \frac{\text{Nombre de classifications correctes}}{\text{Nombre total d'exemples}}$$

Dans notre cas, la précision obtenue est de **96,85%**, ce qui montre que le modèle est capable de classer la majorité des images correctement.

- Précision (Precision) pour les visages générés : La précision pour les visages générés (faux visages) est une mesure qui indique la proportion des images classées comme générées qui sont effectivement des visages générés. Elle est calculée comme suit :

$$\text{Précision} = \frac{\text{Vrais positifs}}{\text{Vrais positifs} + \text{Faux positifs}}$$

La précision pour les visages générés est de **94,75%**, ce qui signifie que le modèle a une bonne capacité à ne pas étiqueter les visages réels comme générés.

- Rappel (Recall) pour les visages générés : Le rappel pour les visages générés mesure la proportion des visages générés correctement identifiés parmi tous les visages générés réels. Il est calculé comme suit :

$$\text{Rappel} = \frac{\text{Vrais positifs}}{\text{Vrais positifs} + \text{Faux négatifs}}$$

Le rappel pour les visages générés est de **94,16%**, ce qui indique que le modèle parvient à détecter la majorité des visages générés, sans trop laisser de faux négatifs.

- Score F1 (F1 Score) : Le score F1 est la moyenne harmonique de la précision et du rappel. Il combine les deux métriques en une seule valeur qui prend en compte à la fois la précision et le rappel, ce qui est particulièrement utile lorsqu'il y a un déséquilibre entre les classes. Il est calculé comme suit :

$$F1Score = 2 \times \frac{Précision \times Rappel}{Précision + Rappel}$$

Le score F1 obtenu est de **94,45%**, ce qui reflète un bon équilibre entre la capacité à classer correctement les images générées et réelles.

Epoch: 1		train_loss: 0.3015		train_acc: 0.8711		test_loss: 0.2152		test_acc: 0.9133
Epoch: 2		train_loss: 0.2134		train_acc: 0.9127		test_loss: 0.1824		test_acc: 0.9261
Epoch: 3		train_loss: 0.1695		train_acc: 0.9328		test_loss: 0.2010		test_acc: 0.9215
Epoch: 4		train_loss: 0.1432		train_acc: 0.9445		test_loss: 0.1731		test_acc: 0.9322
Epoch: 5		train_loss: 0.1215		train_acc: 0.9528		test_loss: 0.1860		test_acc: 0.9343
Epoch: 6		train_loss: 0.1080		train_acc: 0.9591		test_loss: 0.1746		test_acc: 0.9398
Epoch: 7		train_loss: 0.0960		train_acc: 0.9633		test_loss: 0.1860		test_acc: 0.9373
Epoch: 8		train_loss: 0.0853		train_acc: 0.9675		test_loss: 0.2045		test_acc: 0.9385
Epoch: 9		train_loss: 0.0810		train_acc: 0.9699		test_loss: 0.1745		test_acc: 0.9404
Epoch: 10		train_loss: 0.0729		train_acc: 0.9733		test_loss: 0.1883		test_acc: 0.9391

Figure 15: Métriques de Performance du Modèle sur le Jeu de Données de Test et Train.

Les résultats d'un entraînement de modèle sur 10 époques, montrant une amélioration progressive de la précision (accuracy) et une diminution de la perte (loss) à la fois sur les ensembles d'entraînement et de test.

VII. Outils et Technologies

Pour le développement et la mise en œuvre de systèmes de reconnaissance de l'écriture manuscrite (HTR), plusieurs outils et technologies sont essentiels. Voici un aperçu des principales technologies utilisées dans ce projet :

1. Langages de Programmation

Python : Principal langage utilisé pour le développement de modèles d'apprentissage automatique et d'apprentissage profond. Python est préféré pour sa simplicité et son vaste écosystème de bibliothèques scientifiques.

2. Bibliothèques et Frameworks

- **PyTorch** est une bibliothèque open source de calcul numérique et d'apprentissage automatique, largement utilisée pour la recherche et le

développement en intelligence artificielle (IA) et en apprentissage profond (deep learning)



Figure 16:PyTorch

- **NumPy** : Une bibliothèque fondamentale pour le calcul scientifique en Python. NumPy est utilisé pour la manipulation et le traitement des données, notamment pour les opérations sur les tableaux et les matrices.



Figure 17:NumPY

- **Matplotlib** : Une bibliothèque de visualisation en Python utilisée pour créer des graphiques et des visualisations des données, ce qui est utile pour l'analyse et la compréhension des performances des modèles.



Figure 18: Matplotlib

- Gradio : est une bibliothèque Python open source qui permet de créer rapidement des interfaces utilisateur (UI) interactives pour des modèles de

machine learning. Il suffit de quelques lignes de code pour déployer une interface web où les utilisateurs peuvent tester des modèles en entrant des données (images, texte, etc.) et voir les résultats en temps réel. Gradio est particulièrement utile pour partager et démontrer des modèles de manière simple et intuitive.



Figure 19 : gradio

3. Environnements de Développement :

- **Jupyter Notebook** : Un environnement interactif qui permet de créer et de partager des documents contenant du code, des visualisations et du texte narratif. Jupyter Notebook est particulièrement utile pour le prototypage et l'analyse exploratoire des données.
- **Visual Studio Code (VS Code)** : est un éditeur de code source léger, puissante et open source développée par Microsoft. Il prend en charge une multitude de langages de programmation et offre des fonctionnalités avancées comme le débogage, l'intégration Git, les extensions personnalisables et un terminal intégré. VS Code est particulièrement apprécié pour sa rapidité, son interface intuitive et son écosystème riche en extensions, ce qui en fait un outil incontournable pour les développeurs

VIII. Interface graphique :

Interface de l'application "Face-to-Face" : L'interface affiche une image de visage téléchargée par l'utilisateur, accompagnée de la prédiction du modèle indiquant si l'image est réelle ou générée par IA, avec des pourcentages de confiance et le temps

de prédiction. Des boutons permettent de soumettre une image, de l'effacer ou de signaler un résultat.



Figure 20: Interface graphique (real image)




Figure 21: Interface graphique (fake image)

IX. Conclusion

En conclusion, le jeu de données combinant des visages réels et générés par IA offre une base solide pour entraîner un modèle de détection de visages artificiels. La répartition des étiquettes "faux" et "réel" ainsi que la pré-traitance des images ont permis d'assurer une structure cohérente et un prétraitement adapté avant l'entraînement. Le choix du **Transfer Learning**, avec le modèle **ResNet50**, permet de tirer parti des caractéristiques générales déjà apprises par ce modèle, tout en l'adaptant à la détection de visages générés par IA. Cette approche permet non seulement de gagner en efficacité, mais aussi de surmonter les défis posés par la diversité et la complexité des images utilisées dans ce projet.

CONCLUSION

La reconnaissance des images de visages humains générés par l'IA, en utilisant le modèle ResNet50, représente une avancée significative dans le domaine de la vision par ordinateur et de la sécurité numérique. ResNet50, avec son architecture profonde et ses connexions résiduelles, a démontré une capacité remarquable à extraire des caractéristiques complexes et à distinguer les visages réels des visages synthétiques générés par des techniques modernes comme les GANs. Cependant, les défis liés au réalisme croissant des images générées, à l'hétérogénéité des techniques de génération et à l'évolution rapide des technologies nécessitent une vigilance constante et des mises à jour régulières des modèles de détection. Ce projet a permis de mettre en lumière l'efficacité de ResNet50 pour cette tâche, tout en soulignant l'importance de continuer à explorer des approches innovantes pour rester à la pointe de la lutte contre les contenus synthétiques. En fin de compte, la combinaison de modèles robustes comme ResNet50 et de stratégies de détection adaptatives sera essentielle pour garantir la fiabilité des systèmes de reconnaissance faciale dans un paysage numérique en constante évolution.

BIBLIOGRAPHIE

- <https://pytorch.org/vision/main/models/resnet.html>
- <https://paperswithcode.com/method/stylegan>
- <https://keras.io/examples/generative/stylegan/>
- <https://ebooks.iospress.nl/doi/10.3233/FAIA230558>
- <https://www.sciencedirect.com/science/article/pii/S1877050924005787>
- <https://arxiv.org/abs/2401.02627>
- https://openaccess.thecvf.com/content_CVPR_2020/papers/Liu_Global_Texture_Enhancement_for_Fake_Face_Detection_in_the_Wild_CVPR_2020_paper.pdf